

B A C H E L O R A R B E I T

im Studiengang
MEDIENINFORMATIK (MI7)

Semantische Beziehungen in Texten mit Word2Vec

und der Vergleich zwischen allgemeinen und
domänenspezifischen Korpora als Trainingsdaten

vorgelegt von RUBEN MÜLLER
an der Hochschule der Medien Stuttgart,
am 31.07.2015

zur Erlangung des akademischen Grades eines BACHELOR OF SCIENCE

Erstprüfer: PROF. DR-ING. JOHANNES MAUCHER,
Hochschule der Medien, Stuttgart

Zweitprüfer: M.SC. ANDREAS STIEGLER,
Hochschule der Medien, Stuttgart

Erklärung

Hiermit versichere ich, Ruben Müller, ehrenwörtlich, dass ich die vorliegende Bachelorarbeit (bzw. Masterarbeit) mit dem Titel: „Semantische Beziehungen in Texten mit Word2Vec und der Vergleich zwischen allgemeinen und domänenspezifischen Korpora als Trainingsdaten“ selbstständig und ohne fremde Hilfe verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken entnommen wurden, sind in jedem Fall unter Angabe der Quelle kenntlich gemacht. Die Arbeit ist noch nicht veröffentlicht oder in anderer Form als Prüfungsleistung vorgelegt worden.

Ich habe die Bedeutung der ehrenwörtlichen Versicherung und die prüfungsrechtlichen Folgen (§26 Abs. 2 Bachelor-SPO (6 Semester), § 24 Abs. 2 Bachelor-SPO (7 Semester), § 23 Abs. 2 Master-SPO (3 Semester) bzw. § 19 Abs. 2 Master-SPO (4 Semester und berufsbegleitend) der HdM) einer unrichtigen oder unvollständigen ehrenwörtlichen Versicherung zur Kenntnis genommen.

Filderstadt, den 31. Juli 2015

Ruben Müller

Kurzfassung

Diese Bachelorarbeit beschäftigt sich mit der Analyse von semantischen Beziehungen innerhalb mit Word2Vec gelernten Modellen.

Dazu sollen zum einen der allgemeine komplette Wikipedia-Korpus gelernt und analysiert werden, was als semantisch ähnlich erkannt wird. Zum anderen soll ein Korpus über eine spezielle Domäne erstellt und gelernt werden. Welche spezielle Domäne analysiert und verglichen werden soll, wird im Laufe der Bearbeitung festgelegt.

Diese beiden Korpora sollen sich dann gegenüber gestellt und analysiert werden, was jeweils als semantisch ähnlich erkannt wird.

Ziel dieser Arbeit soll es sein, festzustellen ob ein allgemeiner Korpus oder ein spezieller Domänenkorpus genauere Resultate im Hinblick auf semantische Ähnlichkeiten erzielt. Anstatt eines allgemeinen Korpus zu verwenden, könnte es sich dann anbieten zwischen mehreren speziellen Korpora auszuwählen, je nachdem welche Domäne aktuell bearbeitet werden soll.

Abstract

This bachelor thesis deals with the analysis of semantic relations in models which are learned by Word2Vec.

For this purpose on the one hand the whole and general wikipedia body shall be learned and analyzed what is detected as semantic similar. On the other hand a body covering a specific domain shall be created and learned. Which specific domain is chosen will be defined due to the working process.

These both bodies shall then be compared against each other to determine what is recognized as semantic similar.

Goal of this thesis will be to determine whether a general body or a domain specific body gives more precise results with regard to semantic similarity. Instead of using a general body it could be better to choose between multiple domain specific bodies with regard to the actual domain.

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation und Problemstellung	1
1.2	Verwandte Arbeiten	1
1.3	Aufbau der Arbeit	2
2	Daten und Vorverarbeitung	3
2.1	Datenbasis	3
2.2	Externe Programme und Hilfsmittel	3
2.3	Vorverarbeitung	4
3	Word2Vec	5
3.1	CBOW	6
3.2	Skip-gram	6
3.3	Hierarchical softmax	7
3.4	Negative sampling	7
3.5	Parameter	7
4	Wikipedia-Korpus	9
4.1	Gesamtkorpus	9
4.2	Teilkorpus	11
4.3	Testdaten	12
5	Experimente	14
5.1	Synonymsuche durch Rekursion	14
5.2	Konkretisierungen	17
5.3	Verallgemeinerungen	20
5.4	Unterschiedliche Beziehungen	23
5.5	Erkennen von Mehrdeutigkeit	25

6	Fazit und Ausblick	27
6.1	Fazit	27
6.2	Ausblick	28
7	Anhang	32
7.1	Testdatenvergleich	32
7.2	Testdaten	34
7.3	Reinigungsskript	36
7.4	Synonymliste	39

Begriffsverzeichnis

Begriff	Erklärung
Ähnliche Worte	Worte, die im Word2Vec-Modell mit der Methode <i>most_similar()</i> , erhalten werden
SVM	Support Vector Machine
NBC	Naive Bayes Classifier
CBOW	Continuous bag-of-words

Kapitel 1

Einleitung

1.1 Motivation und Problemstellung

Um semantische Beziehungen zwischen Worten abzubilden, gibt es unter anderem die Möglichkeit, Modelle mittels Word2Vec darzustellen. Wie dieses Modell die Beziehungen aufbaut, hängt nicht nur von den Trainingsparametern des Modells ab, sondern auch von den verwendeten Trainingsdaten. So können beispielsweise allgemeine Daten, die keine spezielle Fachdomäne abbilden, als Trainingsdatenkorpus benutzt werden oder aber ausschließlich Daten über eine spezielle Domäne.

In dieser Arbeit wird untersucht, wie sich unterschiedliche Textgrundlagen (Korpora) als Trainingsdaten auf die semantischen Beziehungen zwischen Worten im Word2Vec Modell auswirken.

Die Ergebnisse dieser Arbeit sollen es ermöglichen, dass für eine spezielle Fragestellung oder Anwendung des Word2Vec Modells, das richtige Modell, bzw die richtigen Trainingsdaten ausgewählt werden können.

1.2 Verwandte Arbeiten

1.3 Aufbau der Arbeit

Im folgenden Abschnitt wird kurz der Aufbau dieser Arbeit beschrieben.

Kapitel 2: Daten und Vorverarbeitung

In diesem Kapitel wird erläutert, welche Daten in dieser Arbeit benutzt wurden. Des Weiteren wird kurz erklärt, in welchen Vorverarbeitungsschritten diese Daten bearbeitet wurden um in den nächsten Kapiteln verwendet werden zu können.

Kapitel 3: Word2Vec

Hier werden kurz die unterschiedlichen Möglichkeiten im Word2Vec Modell erklärt und die wichtigsten Parameter vorgestellt.

Kapitel 4: Wikipedia-Korpus

In Kapitel 4 werden der komplette Wikipedia-Korpus sowie ein Teilkorpus daraus vorgestellt und die zum Training des Word2Vec Modells ausgewählten Parameter erläutert. Außerdem werden die Testdaten vorgestellt.

Kapitel 5: Experimente

Kapitel 5 beschäftigt sich mit den Ergebnissen der durch die Testdaten erhaltenen ähnlichen Worte der unterschiedlichen Word2Vec Modelle.

Kapitel 6: Fazit und Ausblick

In Kapitel 6 soll sollen die Ergebnisse der Problemstellung gegenüber gestellt und ein Ausblick auf zukünftige Arbeiten gegeben werden.

Kapitel 7: Anhang

Hier sind die Testdaten und weitere Auflistungen ausführlich dargestellt.

Kapitel 2

Daten und Vorverarbeitung

2.1 Datenbasis

In dieser Arbeit werden unterschiedliche Datenkorpora als Trainingsdaten für unterschiedliche Word2Vec Modelle benutzt. Da zum erfolgreichen Training des Word2Vec Modells eine sehr große Menge an Daten benötigt werden¹, wird für den ersten Korpus der komplette englischsprachige Wikipedia Korpus verwendet². Der zweite in der Arbeit benützte Korpus besteht auch aus Wikipedia Artikeln, allerdings ausschließlich aus technologiespezifischen Artikeln. Hierzu wurde der komplette englische Wikipedia Korpus zuerst in die einzelnen Artikel aufgeteilt und diese wurden dann mit einem NBC in die Klassen *tech*, *entertainment*, *sport*, *science*, *politic* eingeteilt. Im Anschluss wurden dann die als *tech* klassifizierten Artikel zusammengefasst.

2.2 Externe Programme und Hilfsmittel

Dieser Abschnitt enthält eine Auflistung mit kurzen Beschreibungen, der in dieser Arbeit verwendeten Hilfsmittel und externen Programme.

gensim[RŠ10]³ ist eine Bibliothek für Python. Sie enthält unter anderem eine performanzoptimierte Implementierung von Word2Vec.

Der NBC, der zum Klassifizieren der Artikel verwendet wurde, ist der im DataMining Praktikum⁴ selbst implementierte.

¹In [MSC⁺13] werden Trainingsdaten mit bis zu 30 Milliarden Wörtern benutzt.

²Dump von März 2015, <http://dumps.wikimedia.org/enwiki/latest/enwiki-latest-pages-articles.xml.bz2>, abgerufen am 09.04.2015

³<https://radimrehurek.com/gensim/>, abgerufen am 24.06.2015

⁴https://www.hdm-stuttgart.de/~maucher/Data_Mining_SS15.html und https://www.mi.hdm-stuttgart.de/mib/studium/intern/skripte/Data_Mining/WS1213/V4SpamFilter.pdf, abgerufen am 17.07.2015

PyCharm⁵ wurde als Editor und zum Ausführen der Python Skripte verwendet. **Thesaurus** ist ein Webservice⁶, der mittels einer HTTP GET Nachricht, mit den Parametern *word*, *language* und *key*, eine Liste von Synonymen des Wortes *word* liefert. Die Synonyme stammen aus den Thesaurus Lexika von OpenOffice⁷.

2.3 Vorverarbeitung

Der komplette Wikipediadump kann als komprimierte XML-Datei heruntergeladen werden⁸. Die entpackte XML-Datei hat eine Größe von 48,8 GB. Um die Daten als Trainingsdaten für Word2Vec Modelle zu verwenden, müssen diese zuerst bereinigt werden..

Um das Wiki-Markup, wie unter anderem Links, Referenzen oder Zitate, und die XML-Tags zu entfernen, kann ein schon vorgefertigtes Perl Skript von Matt Mahoney benutzt werden⁹, welches von Mikolov et al. auf der Google Code Seite von Word2Vec vorgeschlagen wird¹⁰. Dieses Skript wurde speziell zum Bereinigen von Wikipediadaten erstellt und wurde leicht verändert, sodass Zahlen, Satzzeichen und die Groß- und Kleinschreibung erhalten bleiben. Außerdem werden die Umlaute in *ae*, *oe* und *ue* umgewandelt¹¹. Da die bis hierher bereinigten Daten eine Gesamtgröße von 18 GB haben, ist es nötig die Daten weiter aufzubereiten, sodass sie als Input für die Klasse *gensim.models.word2vec.LineSentence*¹², aus der Gensim Bibliothek dienen. Dazu müssen die einzelnen Sätze in je einer Zeile stehen, alle Worte klein geschrieben, frei von Satzzeichen und mit Leerzeichen getrennt sein.

Um den kompletten Wikipediadump in die einzelnen Wikipedia Artikel aufzuteilen muss die XML-Datei mittels eines SAX-Parsers¹³ geparkt und dann in einzelne Dateien geschrieben werden. Diese einzelnen Dateien können dann mit dem bereits erwähnten Perl Skript gereinigt und dann mittels NBC klassifiziert werden. Nach der Klassifizierung können die Dateien wieder in eine große Datei zusammengefasst und weiter verarbeitet werden. Auch diese Daten müssen, wie der Gesamtkorpus, mit der Klasse *gensim.models.word2vec.LineSentence* verarbeitet werden.

⁵<https://www.jetbrains.com/pycharm/>, abgerufen am 02.07.2015

⁶<http://thesaurus.altervista.org/thesaurus/v1>, abgerufen am 20.07.2015

⁷<https://www.openoffice.org/>, abgerufen am 20.07.2015

⁸<http://dumps.wikimedia.org/enwiki/latest/enwiki-latest-pages-articles.xml.bz2>, abgerufen am 09.04.2015

⁹<http://mattmahoney.net/dc/textdata.html> unter Appendix A, abgerufen am 25.06.2015

¹⁰<https://code.google.com/p/word2vec/>, abgerufen am 25.06.2015

¹¹Für das komplette geänderte Skript siehe Anhang 7.3

¹²Diese Klasse kann auch als Input zum Trainieren des Word2Vec Modells genutzt werden.

¹³Es wurde die Klasse *xml.sax.handler.ContentHandler* verwendet.

Kapitel 3

Word2Vec

Im folgenden Kapitel wird kurz erklärt was Word2Vec¹ ist und welche wichtigen Parameter und Algorithmen bei der Berechnung und dem Erstellen von Word2Vec Modellen benutzt werden können.

Allgemeines zu Word2Vec,
Vergleich zu anderen
syntaktische und semantische Ähnlichkeiten werden mit word2vec abgebildet
Vektoraddition, -subtraktion (<http://www.aclweb.org/anthology/N13-1090>)

In Word2Vec Modellen werden Worte als Vektoren dargestellt². Hier wird mittels *distributed representation* [MCCD13] ein n-dimensionaler Vektorraum erzeugt, in dem jedes Wort aus den Trainingsdaten durch einen Vektor dargestellt wird.

Als nächster Schritt werden die Vektoren in ein neuronales Netz gegeben und dort mittels eines Lernalgorithmus so verändert, dass Worte mit ähnlicher Bedeutung ähnliche Vektoren haben. Die Ähnlichkeit zwischen zwei Worten kann so berechnet werden, indem die Kosinusähnlichkeit zwischen den Vektordarstellungen der beiden Worte gebildet wird.

Die Berechnung der Wortvektoren kann mit neuronalen Netzen unterschiedlicher Architektur erreicht werden, *CBOW* oder *Skip-gram*. Desweiteren stehen unterschiedliche Lernalgorithmen für die neuronalen Netze zur Verfügung, *hierarchical softmax* und *negative sampling*.

Beim Training können unterschiedliche Parameter eingestellt werden.

¹<https://code.google.com/p/word2vec/>

²Word2Vec heißt wörtlich Wort zu Vektor.




Abbildung 3.1: CBOW und Skip-gram im Vergleich, übersetzt nach [MCCD13]

3.1 CBOW

CBOW ist die Abkürzung für Continuous bag-of-words (dt. stetige Menge an Worten). Beim CBOW wird ein neuronales Netz ohne verdeckte Schichten (hidden layer) verwendet [MCCD13].

In der CBOW Architektur wird aus dem Kontext ein Wort vorhergesagt (siehe Abbildung 3.1). Die Anzahl, der aus dem Kontext zu verwendende Worte, wird mit dem Parameter *window* angegeben.

3.2 Skip-gram

Bei der Skip-gram Architektur wird auch, wie beim CBOW Model, ein neuronales Netz ohne verdeckte Schichten (hidden layer) verwendet [MCCD13].

Allerdings wird hier nicht ein Wort aus dem Kontext vorhergesagt, sondern aus einem Wort wird der Kontext vorhergesagt (siehe Abbildung 3.1).

Mehrere verdeckte Schichten in neuronalen Netzen machen die Modelle genauer, allerdings kommt auch die meiste Komplexität des ganzen Models von solchen verdeckten Schichten [MCCD13]. Mikolov et al. haben deshalb neuronale Netze ohne verdeckte Schichten bevorzugt, da damit sehr große Datenmengen viel effizienter gelernt werden können.

3.3 Hierarchical softmax

Eine Annäherung an das allgemeine softmax ist das hierarchical softmax [MSC⁺13]. Der Hauptvorteil ist, dass anstatt W Ausgabeknoten im neuronalen Netz nur ungefähr $\log_2(W)$ Knoten ausgewertet werden müssen um die Wahrscheinlichkeiten zu errechnen.

Bei diesem Lernalgorithmus wird das Wörterbuch als Huffman Binärbaum dargestellt. Dies hat den weiteren Vorteil, dass häufig genutzte Worte kurze Kodierungen haben, was sich auf das Trainingstempo positiv auswirkt.

3.4 Negative sampling

Alternativ zum hierarchical softmax kann das negative sampling als Lernalgorithmus für das neuronale Netz verwendet werden [MSC⁺13].

Das negative sampling unterscheidet sich zum hierarchical softmax insofern, dass nicht die Ähnlichkeiten zu anderen Worten berechnet werden, sondern es wird davon ausgegangen, dass zufällig ausgewählte Worte mit einer hohen Wahrscheinlichkeit unähnlich, dem zu testenden Wort, sind. Wie viele solcher zufällig ausgewählter Worte benutzt werden sollen kann mit dem Parameter *negative* angegeben werden.

3.5 Parameter

size

Mit dem Parameter *size* wird die Anzahl der Dimensionen der Wortvektoren eingestellt. In einem n -dimensionalen Vektorraum nimmt n den Wert von *size* an.

window

window ist der maximale Abstand zwischen benachbarten Worten, innerhalb eines Satzes, die zur Berechnung der Wordvektoren betrachtet werden.

min_count

Der Parameter *min_count* gibt an, wie oft ein Wort in den Testdaten mindestens vorkommen muss, um in das Wörterbuch aufgenommen zu werden.

negative

Dieser Parameter wird nur benötigt, wenn als Lernalgorithmus negative sampling verwendet wird³. Er gibt an, wie viele zufällig ausgewählten Worte verwendet werden sollen.

³siehe 3.4 Negative sampling

Kapitel 4

Wikipedia-Korpus

Im Folgenden Kapitel werden die in der Arbeit verwendeten Korpora erläutert und die im Word2Vec Modell benutzten Parameter begründet. Des Weiteren werden die benutzten Testdaten vorgestellt.

4.1 Gesamtkorpus

Da sich die Qualität der Wortvektoren im Word2Vec Modell wesentlich mit der Menge an Trainingsdaten erhöht[MCCD13], werden möglichst große Textkorpora bevorzugt. Auf der Google Code Seite von Word2Vec¹, werden für Forschungszwecke einige Beispiele für online verfügbare große Korpora genannt, dazu zählt unter anderem auch der neueste Wikipedia Auszug².

Da in dieser Arbeit ein allgemeiner und ein domänenspezifischer Korpus als Trainingsdaten für das Word2Vec Modell verglichen werden, eignet sich der Wikipedia Korpus besonders gut.

Wie in 2.3 beschrieben, müssen die Daten erst einer Säuberung unterzogen werden, um dann anschließend für das Training im Word2Vec Modell benutzt zu werden.

Der bereinigte, komplette englischsprachige Wikipedia Korpus³ enthält 8.392.453 Artikel, 242.144.317 Sätze und 2.919.802.692 Worte.

Die Skip-gram Architektur verhält sich im Bezug auf syntaktische Ähnlichkeit etwas schlechter als die CBOW Architektur, allerdings ist die Skip-gram Architektur im Bezug auf semantische Ähnlichkeit der CBOW weit überlegen[MCCD13].

¹<https://code.google.com/p/word2vec/>, abgerufen am 29.06.2015

²<http://dumps.wikimedia.org/enwiki/latest/enwiki-latest-pages-articles.xml.bz2>, abgerufen am 29.06.2015

³Dump von März 2015, <http://dumps.wikimedia.org/enwiki/latest/enwiki-latest-pages-articles.xml.bz2>, abgerufen am 09.04.2015

Aus diesem Grund wurde die Skip-gram Architektur ausgewählt.

Da der *hierarchical softmax* Lernalgorithmus eher für selten vorkommende Worte und der *negative sampling* Lernalgorithmus eher für häufig vorkommende Worte und niedrigdimensionale Vektoren geeignet ist⁴, wurde der *hierarchical softmax* Lernalgorithmus gewählt, da das Modell (wie im Folgenden gezeigt wird), eine hohe Dimension an Vektoren hat und auf technologiespezifische Daten getestet werden soll (siehe 7.2 Testdaten).

Um die optimalen Parameter für das Training des Modells herauszufinden wurde ein kleinerer Wikipedia Auszug⁵ als Trainingsdaten benutzt und mit unterschiedlichen Parametern wurden mehrere Modelle gelernt und evaluiert (siehe Tabelle 4.1). Die Word2Vec-Klasse in der Gensim-Implementierung beinhaltet eine Evaluationsfunktion⁶, die die Accuracy des Modells berechnet. Die Funktion erwartet einen Dateinamen einer Datei, in der jede Zeile ein 4-Tupel ist und die einzelnen Abschnitte mit „: SECTION NAME“ unterteilt sind. Ein solches 4-Tupel besteht aus zwei Wortpaaren, deren Worte die gleiche Beziehung untereinander haben, zum Beispiel „Athens Greece Berlin Germany“, hier stellen beide Wortpaare die Beziehung zwischen einem Land und dessen Hauptstadt dar. Auf der Google Code Seite ist eine solche Datei als Beispiel vorhanden⁷. In diesem Beispiel sind 14 Kategorien⁸ mit insgesamt 19544 4-Tupel aufgelistet.

Das Word2Vec Modell stellt eine Funktion bereit, *most_similar(positive=[], negative=[], topn=N)*, bei der die Vektoren der Wörter im Array *positive* aufaddiert und die Vektoren der Wörter in *negative* davon subtrahiert werden. Die Funktion liefert die *N* Wörter zurück, deren Vektordarstellungen eine maximale Kosinusähnlichkeit mit dem Ergebnis der Vektoraddition und -subtraktion haben. Diese Funktion wird auch in der Evaluationsfunktion benutzt, indem die ersten drei Wörter des 4-Tupels in *positive* und *negative* eingeteilt werden⁹, wird das vierte Wort, hier ‚Germany‘, korrekt vom Modell vorhergesagt, wird dieser Testdatensatz als erfolgreich gezählt. Sollten Wörter nicht im Modell dargestellt sein, wirkt sich dies nicht negativ auf die Accuracy aus, denn die Gesamtaccuracy eines Modells wird als Verhältnis, zwischen

⁴<https://code.google.com/p/word2vec/#Performance>, abgerufen am 01.07.2015

⁵<http://mattmahoney.net/dc/enwik9.zip>, abgerufen am 30.06.2015, beinhaltet die ersten 1 Milliarde Zeichen des Gesamtkorpus

⁶*gensim.models.word2vec.Word2Vec.accuracy(FILENAME)*

⁷<https://code.google.com/p/word2vec/source/browse/trunk/questions-words.txt>, abgerufen am 29.06.2015

⁸*capital-common-countries, capital-world, currency, city-in-state, family, gram1-adjective-to-adverb, gram2-opposite, gram3-comparative, gram4-superlative, gram5-present-participle, gram6-nationality-adjective, gram7-past-tense, gram8-plural, gram9-plural-verbs*

⁹*most_similar(positive=['Greece','Berlin'], negative=['Athens'], topn=1)*

der Anzahl der richtig vorhergesagten Wörter und der Anzahl der Testdatensätze, bei denen alle Wörter eine Vektordarstellung im Modell haben, dargestellt. In der Tabelle 4.1 werden die unterschiedlichen Parameter¹⁰ und die erreichte Gesamtaccuracy dargestellt. In diesem Modell waren nur bei 13144 der 19544 4-Tupel alle Wörter als Vektordarstellungen im Modell vorhanden.

Tabelle 4.1: Vergleich Parameter

Size	Window	Min_count	Gesamtaccuracy
400	10	5	53,5% (7027/13144)
400	10	10	52,5% (6905/13144)
300	10	5	52,5% (6860/13144)
300	10	10	52,9% (6951/13144)
200	10	5	50,5% (6632/13144)
200	10	10	50,5% (6636/13144)
100	10	5	42,0% (5517/13144)
100	10	10	41,3% (5431/13144)

Auf dem kleineren Wikipedia Korpus erzielte das Modell mit den Parametern $size = 400$, $window = 10$, $min_count = 5$ die beste Gesamtaccuracy mit 53,5%. Diese Parameter wurden auf das Gesamtmodell übertragen. Die Trainingszeit beträgt bei diesen Parametern 10,5h¹¹ beim Gesamtmodell. Nachdem ein kleinerer Fehler im Reinigungsskript aufgetreten war¹², musste das komplette Modell nochmals gelernt werden. Hier fiel dann die Entscheidung, andere Parameter zu benutzen und die $window$ Größe auf 300 zu reduzieren, da dies die Accuracy nur sehr gering verändert und sich die Trainingszeit auf 7,7h verkürzte. Dies zahlte sich im Laufe der Arbeit aus, da sich das Perl-Reinigungsskript ein paar Mal geringfügig änderte um so kleinere Fehler aus dem Korpus zu entfernen.

4.2 Teilkorpus

Der zweite Korpus ist ein Teilkorpus des Gesamtkorpus, bestehend aus Technologieartikeln. Um diesen Korpus zu erstellen, muss der Gesamtkorpus, wie in 2.3 beschrieben, zuerst in die einzelnen Wikipediaartikel unterteilt werden. Diese Arti-

¹⁰Siehe 3.5. Auf der Google Code Seite von Word2Vec wird eine window size bei der Skip-gram Architektur von 10 vorgeschlagen, somit wird sie hier nicht verändert.

¹¹Leistungsdaten: PC mit 32 GB RAM, i7-3770 Quadcore bei 3,4 GHz

¹²Unbekannte Zeichen wurden mit einem Leerzeichen ersetzt, anstatt gelöscht zu werden, somit entstanden Wortfragmente als eigene Worte.

kel werden dann mithilfe eines NBC klassifiziert. Ein NBC basiert auf dem Prinzip des überwachten Lernens. Hierzu müssen vor dem Training von Hand ausgewählte Artikel¹³ in die fünf zu klassifizierenden Themenbereiche¹⁴ eingeteilt werden. In jeder Kategorie wurden gleich viele Artikel ausgewählt, somit entsteht kein Ungleichgewicht beim Training. Es wurden je Kategorie 100 Artikel verwendet. Mit diesen Daten kann der NBC dann trainiert werden. Im Anschluss daran, kann der NBC dann für die Klassifikation der Wikipediaartikel verwendet werden. Die Artikeln, die in die Kategorie *tech* eingeteilt werden, bilden dann den technologiespezifischen Teilkorpus, der als zweiter Korpus in dieser Arbeit verwendet wird.

Dieser domänenspezifische Teilkorpus enthält 187.144 Artikel (2,2% im Vergleich zum Gesamtkorpus), 9.866.096 Wörter(0,34%) und 3.166.065 Sätze(1,3%). Hier beträgt die Trainingszeit ca. 2 Minuten.

Wird dieser Korpus mit der *.accuracy()*-Methode evaluiert, erreicht er eine Gesamtaccuracy von nur 7,0%. Das hat den Grund, dass die Testfragen von allgemeiner Art sind und diese Beziehungen in einem reinen Technologiekorpus sehr selten bis gar nicht vorkommen.

Die Wahl von anderen Daten, beispielsweise könnten Korpora aus Foren zu technologischen Themen oder Technews Internetseiten, automatisch mittels Crawling, erstellt werden, wäre auch möglich gewesen. Die Verwendung des Wikipedia Teilkorpus ist jedoch zielführender, da hier die gleichen Texte in beiden Korpora vorhanden sind und somit auch die gleichen Beziehungen zwischen den einzelnen Wörtern, um so einen möglichst objektiven Vergleich zwischen den unterschiedlichen Korpora zu ermöglichen.

4.3 Testdaten

Im folgenden Kapitel sollen die beiden Word2Vec Modelle, deren Trainingsdaten aus dem Gesamtkorpus, beziehungsweise dem Technologiekorpus bestehen, miteinander verglichen werden. Für diesen Vergleich werden einige Experimente durchgeführt (siehe 5.1 - 5.5), in diesen Experimenten werden die semantischen Beziehungen zwischen Wörtern betrachtet. Um diese Experimente durchführen zu können, werden Testdaten benötigt.

¹³Siehe Anhang CD-Rom!

¹⁴tech, entertainment, sport, science, politic

Es wird die Annahme getroffen, dass die Testdaten aus der Domäne Technologie (oder einer Unterdomäne) stammen müssen, da das Vokabular eines Modells aus Technologieartikeln besteht und auf diesen trainiert wird und da dann eher sichergestellt ist, dass diese Wörter auch wirklich im Modell vorhanden sind und somit eine Vektordarstellung haben.

Um diese Annahme zu überprüfen, wurden aus den drei Domänen *Medizin*, *Mode/Fashion* und *Technologie/Pc/Internet* je 50 Begriffe ausgewählt um zu testen, ob diese überhaupt im Technologiemodell vorhanden sind¹⁵. Die Begriffe wurden von Hand aus Wikipedia Artikeln ausgesucht, um sicherzustellen, dass diese Begriffe im Gesamtmodell eine Vektorrepräsentation haben.

Wird im Word2Vec Modell mit der Methode `most_similar(positive=[‘word’], topn=1)` nach ähnlichen Wörtern gesucht, aber das Suchwort ist nicht im Modellvokabular vorhanden, wirft diese Methode eine „KeyError“-Exception. Dieses Verhalten wird bei den Tests zur Überprüfung, ob die Testbegriffe im Modellvokabular vorhanden sind, benutzt. Es wird gezählt, bei wie vielen Suchbegriffen eine solche Exception geworfen wird und diese somit nicht im Modell enthalten sind.

Die folgende Tabelle zeigt die Resultate der Worttests. Es sind Domäne, Gesamtanzahl an Testdaten, im Modell gefundene Testdaten und im Modell nicht gefundene Testdaten dargestellt.

Tabelle 4.2: Testdatenvergleich

Domäne	Gesamtanzahl	gefundene Testdaten	nicht gefundene Testdaten
Medizin	50	33	17
Mode/Fashion	50	20	30
Technologie/Pc/Internet	50	45	5

Die Resultate zeigen, dass am meisten Testdaten aus der Domäne *Technologie/Pc/Internet* im Modell gefunden werden. Somit bestätigt sich die Annahme, dass die Testdaten auch aus dieser Domäne stammen sollten. Die Testdaten wurden dann auf 236 Begriffe erweitert¹⁶.

¹⁵Eine vollständige Auflistung dieser Daten ist im Anhang unter 7.1 Testdatenvergleich zu finden.

¹⁶Siehe Anhang 7.2 Testdaten.

Kapitel 5

Experimente

In diesem Kapitel sollen die beiden unterschiedlichen Word2Vec Modelle mit ihren Trainingskorpora (Gesamtkorpus und Techkorpus) untersucht werden. Dies soll durch fünf Experimente realisiert werden. In allen Experimenten werden semantischen Beziehungen zwischen Wörtern untersucht. Dabei ist jedes Experiment in drei Teile aufgeteilt, Beschreibung, Durchführung und Interpretation/Ergebnis.

Als Grundlage für die Experimente dienen die Testdaten¹ und die mit der Methode *most_similar()*² gefunden fünf ähnlichsten Worte. Zum Vergleichen der ähnlichen Worte der unterschiedlichen Korpora wurde eine Datei erzeugt, in der die Testdaten und ihre fünf ähnlichsten Worte, mit den dazugehörigen Kosinusähnlichkeiten, leserlich formatiert, ausgegeben werden.

5.1 Synonymsuche durch Rekursion

Beschreibung

Im ersten Experiment wird untersucht, ob es möglich ist, im Word2Vec Modell Synonyme eines Begriffs zu finden. Hierzu sollen allerdings nicht die ähnlichen Worte der Testbegriffe betrachtet werden, sondern deren ähnliche Worte. Die Suche nach ähnlichen Worten wird somit ein Mal rekursiv angewandt. Die Überlegung ist, dass durch den rekursiven Aufruf Rückbeziehungen zu den ursprünglichen Suchbegriffen und deren Synonymen entstehen. Eine Anwendung für die Synonymsuche durch Rekursion könnte ein Thesaurus-Lexikon sein.

¹Siehe 7.2 Testdaten

²`gensim.models.word2vec.Word2Vec.most_similar()`

Durchführung

Eine Liste mit den Synonymen der Testbegriffe wird vor dem Experiment mit der Hilfe eines Webservices³ erstellt⁴. Dieser Webservice liefert aber nur für 109 der insgesamt 236 Testwörter Synonyme. So wurden für dieses Experiment nur diese 109 Testwörter benutzt.

Im ersten Schritt dieses Experiments müssen die ähnlichen Worte (W_1) der Testbegriffe, mit der Methode *most_similar()* des Word2Vec Modells, herausgefunden werden. Diese fünf Wörter (W_1) werden in der späteren Analyse nicht betrachtet. Im nächsten Schritt werden die fünf erhaltenen ähnlichen Wörter (W_1) dann als Eingabe für die *most_similar()*-Methode benutzt und liefern wieder jeweils fünf ähnliche Wörter (W_2) zurück. Die insgesamt 25 Begriffe werden im letzten Schritt des Experiments dann mit den Synonymen des ursprünglichen Testbegriff verglichen. Sobald einer der 25 erhaltenen Begriffe in der Liste der Synonyme des jeweiligen Testwortes enthalten ist, wird dieses Wort als *Synonym enthalten* gezählt.

Die nachfolgende Tabelle listet die Resultate dieses Experiments auf. Es sind die Gesamtanzahl der Testwörter, die Anzahl an Testwörter, bei denen Synonyme gefunden wurden und die Anzahl der Testwörter, bei denen keine Synonyme gefunden wurden, sowie die Anzahl der Worte, die nicht im jeweiligen Modell enthalten sind, abgebildet.

Tabelle 5.1: Experiment 1: Synonyme durch Rekursion

Korpus	Gesamtanzahl	Synonyme nicht enthalten	Synonyme enthalten	Worte nicht im Korpus
Komplett	109	97	12	0
Technologie	109	102	2	5

³Über <http://thesaurus.altervista.org/>, abgerufen am 20.07.2015

⁴Siehe 7.4

Tabelle 5.2: Beispiele von Synonyme durch Rekursion

Suchbegriff	Modell	Synonym
engineering	Technologie	discipline
power	Technologie	supply
auto	Komplett	automobile
automobile	Komplett	car
cyberwar	Komplett	cyberterrorism
encryption	Komplett	cryptography
google	Komplett	search
linux	Komplett	unix
mouse	Komplett	rodent
processor	Komplett	cpu
sun	Komplett	star
telecom	Komplett	telecommunication
television	Komplett	tv
wifi	Komplett	wlan

In der Tabelle 5.2 sind alle gefundenen Synonyme und die dazugehörigen Testwörter, sowie der Korpus in dem sie auftreten, aufgelistet.

Interpretation/Ergebnis

Wie aus den Daten hervorgeht, werden im Gesamtmodell nur bei zwölf, im Technologiemodell nur bei zwei Testbegriffen Synonyme gefunden. Ein Grund, der die geringe Anzahl an Synonymen erklären könnte, könnte mit der räumlichen Darstellung der Worte im Word2Vec Modell zusammenhängen. Die ähnlichen Worte (W_1) eines Suchbegriffs (O) haben einen minimalen räumlichen Abstand zum Suchbegriff (O). Die durch die Rekursion erhaltenen ähnlichen Worte (W_2) der ähnlichen Worte (W_1), haben wieder einen minimalen räumlichen Abstand (zu W_1), allerdings ist der Abstand vom ursprünglichen Suchbegriff (O) zu den in W_2 enthaltenen Wörter größer als zu den Worten aus W_1 , denn sonst wären sie schon in der Menge W_1 enthalten. Also sind diese Wörter noch weiter vom ursprünglichen Suchbegriffs (O) entfernt und somit unähnlicher. Somit ist das Finden von Synonymen durch Rekursion im Word2Vec Modell nicht zielführend.

Des Weiteren kann das Ergebnis mit den verwendeten Synonymen zusammen hängen. Werden ausführlichere Listen mit Synonymen verwendet, sollte sich damit auch die Anzahl der vom Modell gefundenen Synonyme erhöhen.

5.2 Konkretisierungen

Beschreibung

In diesem Experiment soll hauptsächlich das domänenspezifischen Technologiemodell untersucht werden. Es wird untersucht, ob die ähnlichen Wörter der Testdaten eine Konkretisierung des jeweiligen Suchbegriffs darstellen. Dies ist gerade bei mehrdeutigen Wörtern interessant, da dann eine Sinnrichtung in den ähnlichen Wörtern dominant vertreten sein könnte und somit klar ist, in welchem Kontext das mehrdeutige Wort in dieser Domäne gemeint ist. Es wird vermutet, dass im Technologiemodell die Konkretisierungen stärker vorhanden sind als im allgemeinen Modell. In diesem Experiment werden wieder alle 236 Testdaten verwendet.

Es wird definiert, dass von einer Konkretisierung gesprochen werden kann, wenn das ähnliche Wort eine genauere Bedeutung des Suchbegriffs darstellt (z.B. wird *Wissenschaftler* durch *Physiker* konkretisiert). In der Abbildung 5.1 sind die Abstraktionsbeziehungen zwischen Wörtern als Baumdiagramm dargestellt. Gelb markiert ist der aktuelle Suchbegriff, alle Kindknoten des Suchbegriffs sind grün markiert, hier kann von einer Konkretisierung des Suchbegriffs gesprochen werden. Rot markiert sind alle anderen Knoten, hier kann nicht von einer Verallgemeinerung gesprochen werden. Zur vereinfachten Darstellung ist die Abbildung in 2D und mit einer einfachen Struktur ausgewählt, in komplizierteren Beispielen, unter anderem auch mit mehrdeutigen Begriffen, muss überlegt werden ob eine solche Darstellung überhaupt noch möglich ist.




Abbildung 5.1: Beispiel der Beziehungen zwischen Wörtern als Baumdiagramm dargestellt.

Durchführung

Die Fragestellung bezieht sich zwar eigentlich auf das domänenspezifische Modell, allerdings wurde auch das allgemeine Modell auf diese Fragestellung hin untersucht um festzustellen, ob dieses tatsächlich ein schlechteres Verhalten bezüglich der Anzahl an gefundenen Konkretisierungen aufweist.

Bei diesem Experiment werden die Testwörter mit ihren fünf ähnlichsten Wörtern verglichen. Diese Untersuchung erfolgt von Hand, da es keine Auflistungen mit Konkretisierungen von Begriffen gibt. Außerdem wäre es zu aufwändig, eine solche Liste zu erstellen, da nicht vorhersehbar ist, wie stark die Suchbegriffe konkretisiert werden und somit sehr viele Daten erzeugt werden müssten. Sollten die Modelle hinsichtlich der Konkretisierungstiefe⁵ untersucht werden, könnte das in einem zusätzlichen Experiment analysiert werden. Dann müssten solche Auflistungen mit Konkretisierungen von Begriffen erstellt werden, um das unterschiedliche Verhalten aufzuzeigen. In diesem Experiment geht es aber darum, erst einmal herauszufinden, ob überhaupt eine Konkretisierung stattfindet unabhängig von der Konkretisierungstiefe.

Stellen mindestens drei der fünf ähnlichen Wörter eine Konkretisierung des Suchbegriffs dar, so wird dieser Eintrag als *konkretisiert* markiert. Bei diesem Experiment war das Nachschlagen von mehreren ähnlichen Worten sehr zeitintensiv, denn um beurteilen zu können, ob es sich bei diesem Wort um eine Konkretisierung des Suchbegriffs handelt, müssen die inhaltlichen Beziehungen zwischen Suchbegriff und ähnlichen Worten klar sein. Um die Bedeutungen der Worte und die inhaltlichen Beziehungen zu recherchieren, wird Wikipedia⁶ und Google⁷ benutzt.

In der folgenden Tabelle ist die Gesamtanzahl der Testwörter, die Anzahl der Suchbegriffe, die mit *konkretisiert* markiert wurden, die Anzahl der Suchbegriffe, die nicht mit *konkretisiert* markiert wurden, sowie die Anzahl der nicht im Modell enthaltenen Worte. Die Daten sind nach Modellen getrennt aufgelistet. Des Weiteren sind einige Beispiele in Tabelle 5.4 aufgelistet. Diese Tabelle enthält neben den Suchbegriffen, Modell und den gefundenen konkretisierten ähnlichen Worten auch die Kosinusähnlichkeiten zu den Suchbegriffen.

⁵Damit ist gemeint ob z.B. der Begriff *Auto* mit *BMW*, *Mercedes*, *VW* oder aber mit *X5*, *A-Klasse*, *Tuareg* konkretisiert wird.

⁶<https://en.wikipedia.org/>, abgerufen am 21.07.2015

⁷<https://www.google.de/>, abgerufen am 21.07.2015

Tabelle 5.3: Experiment 2: Konkretisierung

Modell	Gesamtzahl	ähnliche Worte nicht konkretisiert	ähnliche Worte konkretisiert	Wort nicht im Korpus
Komplett	236	199	37	0
Technologie	236	146	65	25

Tabelle 5.4: Beispiele zur Konkretisierung

Suchbegriff	Modell	Konkretisierung
apple	Technologie	iphone (Kosinusähnlichkeit: 0,587), a6x (0,579) ipad (0,570), a5x (0,559)
architecture	Komplett Technologie	revival (0,774), neoclassical (0,677), gothic (0,667) armv7a (0,514), multicore (0,493), xmos (0,477)
fat	Technologie	exfat (0,751), vfat (0,724), fat32 (0,709)
intel	Technologie	i7 (0,707), t2300 (0,702), i5 (0,666), i52450m (0,663)
photography	Technologie	slrs(0,544), panoramic (0,543), polaroid (0,531)
power	Komplett	electricity (0,679), surgut2 (0,637), egbin (0,627)

Interpretation/Ergebnis

Im Technologiemoell konkretisieren in 65 der 236 Testfälle die ähnlichen Worte den jeweiligen Suchbegriff, im Gesamtmodell jedoch nur in 37 Fällen. Somit bestätigt sich die Annahme, dass im Gesamtmodell weniger Konkretisierungen auftreten. Dies hat den Grund, dass sich die Daten im Gesamtmodell nicht auf eine Fachrichtung beschränken wie im Technologiemoell. So werden beim Training mit Technologie-daten im Word2Vec Modell die Beziehungen beibehalten, die beim Training mit dem kompletten Wikipediakorpus durch andere, allgemeine Wörter noch weiter verändert werden.

TODO: Insgesamt wenig Konkretisierungen, da Wörter-BEziehungen so entstehen, dass wo im gleichen zusammenhang stehen, werden als ähnlich erkannt.

Zu beobachten ist, dass der Technologiekorpus besser konkretisiert, als der komplette allgemeine Korpus. Da dies aber nur in ca. 30% der Testfälle passiert, ist es schwierig, zu verallgemeinern, dass die ähnlichen Worte im Technologiekorpus eine

Konkretisierung sind, somit ist auch hier die Annahme des Experiments widerlegt.

5.3 Verallgemeinerungen

Beschreibung

In diesem Experiment wird analysiert, ob die ähnlichen Worte eines Begriffs eine Verallgemeinerung dessen darstellen. Es wird außerdem untersucht, ob im allgemeinen Gesamtmodell mehr Begriffe in ihren ähnlichen Wörtern verallgemeinert werden, als im Technologiemoell. Ein Anwendungsbeispiel für die Verallgemeinerung der Suchbegriffe könnte ein Lexikon sein, bei dem die Worte mit ähnlichen Begriffen beschrieben werden. In diesem Experiment werden wieder alle 236 Testdaten verwendet.

Es wird definiert, dass von einer Verallgemeinerung gesprochen werden kann, wenn das ähnliche Wort eine abstraktere Bedeutung des Suchbegriffs darstellt (z.B. wird *Physiker* durch *Mensch* verallgemeinert) oder das ähnliche Wort bildet einen vergleichbaren Begriff (kein Synonym) ab (z.b. kann *Physiker* mit *Chemiker* verallgemeinert werden). In der Abbildung 5.2 sind die Abstraktionsbeziehungen zwischen Wörtern als Baumdiagramm dargestellt. Gelb markiert ist der aktuelle Suchbegriff, Elternknoten und direkte Geschwisterknoten sind grün markiert, hier kann von einer Verallgemeinerung des Suchbegriffs gesprochen werden. Rot markiert sind die Kindknoten und weiter entfernte Knoten, hier kann nicht von einer Verallgemeinerung gesprochen werden. Zur vereinfachten Darstellung ist die Abbildung in 2D und mit einer einfachen Struktur ausgewählt, in komplizierteren Beispielen, unter anderem auch mit mehrdeutigen Begriffen, muss überlegt werden ob eine solche Darstellung überhaupt noch möglich ist.

Durchführung

In diesem Experiment werden die Testdaten, wie im vorherigen Experiment, mit ihren fünf ähnlichsten Wörtern verglichen. Auch diese Untersuchung wird von Hand durchgeführt, denn auch hier soll, wie im vorherigen Experiment, erst einmal untersucht werden, ob Verallgemeinerungen überhaupt auftreten. In einem weiteren Experiment könnte auch hier untersucht werden, welchen Grad die Verallgemeine-

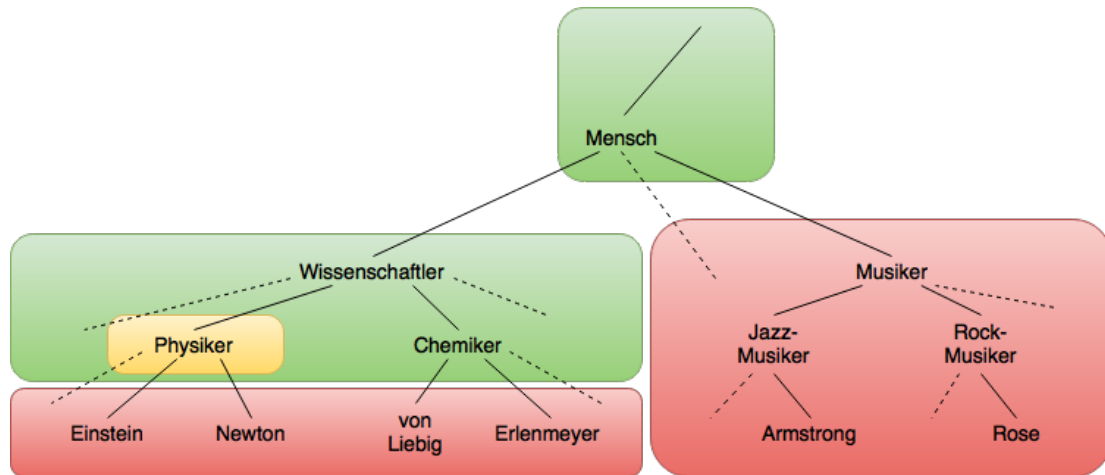


Abbildung 5.2: Beispiel der Beziehungen zwischen Wörtern als Baumdiagramm dargestellt.

rungen haben⁸. Verallgemeinern drei der fünf ähnlichen Worte den Suchbegriff, wird dieser als *verallgemeinert* markiert.

Wie beim vorherigen Experiment mussten viele Begriffe nachgeschlagen werden, um die inhaltlichen Beziehungen zwischen dem Suchbegriff und den jeweiligen ähnlichen Worten beurteilen zu können.

In Tabelle 5.5 sind die Gesamtzahl der Testwörter, die Anzahl der Suchbegriffe, die mit *verallgemeinert* markiert wurden, die Anzahl der Suchbegriffe, die nicht mit *verallgemeinert* markiert wurden, sowie die Anzahl der Worte, die nicht im Modell enthalten sind. Die Daten sind nach Modellen getrennt aufgelistet. Die Tabelle 5.6 enthält einige Beispiele der gefundenen Verallgemeinerungen. Es sind neben den Suchbegriffen, Modell und den gefundenen verallgemeinerten ähnlichen Worten, auch deren Kosinusähnlichkeiten zu den Suchbegriffen.

Tabelle 5.5: Experiment 3: Verallgemeinerung

Modell	Gesamtzahl	ähnliche Worte nicht verallgemeinert	ähnliche Worte verallgemeinert	Wort nicht im Korpus
Komplett	236	102	134	0
Technologie	236	144	67	25

⁸Damit ist gemeint ob *Albert* mit *Einstein*, *Physiker*, *Wissenschaftler* oder *Mensch* verallgemeinert wird.

Tabelle 5.6: Beispiele zur Verallgemeinerung

Suchbegriff	Modell	Verallgemeinerung
apple	Komplett	blackberry (Kosinusähnlichkeit: 0,704), raspberry (0,657), webos (0,643)
asus	Komplett	netbook (0,767), lenovo (0,736), motherboards (0,714)
cookies	Komplett	baked (0,666), cakes (0,663), muffins (0,654)
dell	Komplett	hewlettpackard (0,583), cisco (0,548), lenovo (0,515), compaq (0,506)
limewire	Komplett	bittorrent (0,703), flesharing (0,702), kazaa (0,689) rapidshare (0,668), gnutella (0,653)

Interpretation/Ergebnis

Im Gesamtmodell weißten bei 134 Testbegriffen mindestens drei der dazugehörigen ähnlichen Worte eine Verallgemeinerung des Testwortes auf. Im Technologiemo- dell ist dies nur bei 67 Begriffen der Fall. Somit bestätigt sich die Vermutung, dass im Gesamtmodell mehr Verallgemeinerungen zu finden sind. Dies hängt mit der Tat- sache zusammen, dass das Gesamtmodell mit Daten, die nicht auf ein spezielles Thema beschränkt sind, trainiert wurde und diese Begriffe in allen unterschiedli- chen Zusammenhängen im Trainingskorpus enthalten waren.

TODO: Die Begriffe müssen deshalb öfter in allgemeinen Zusammenhängen in den Trainingsdaten vorgekommen sein, als speziell über das konkrete Thema. Da- durch wurde das Modell beim Training beeinflusst.

Da im Gesamtmodell in mehr als der Hälfte der Fälle, eine Verallgemeinerung der Suchbegriffe in den ähnlichen Daten festgestellt wurde, kann davon ausgegan- gen werden, dass durch die ähnlichen Worte in, mit allgemeinen Daten trainierten, Modellen die Suchbegriffe allgemeiner dargestellt werden.

5.4 Unterschiedliche Beziehungen

Beschreibung

Die inhaltlichen Beziehungen zwischen Wörtern können von unterschiedlicher Art sein. So können die Wörter ***Gleiches*** darstellen, beispielsweise stellen sowohl „drop-

box“, als auch „icloud“ oder „onedrive“ Cloud-Speicher dar. Außerdem können Wörter auch **Gegenteiliges** darstellen, wie z.B. „heiß“ und „kalt“. **Syntaktisch** ist eine weitere Beziehungsart, wie bei „Verschlüsselung“ und „verschlüsseln“. „Automobil“ und „KFZ“ haben eine **synonyme** Beziehung untereinander. Trifft keine der bisher genannten Arten auf die Beziehung zwischen zwei Wörtern, diese haben aber trotzdem etwas miteinander zu tun, wie beispielsweise „Motor“ und „Benzin“, dann stehen diese Begriffe **in Beziehung** miteinander. Diese fünf Beziehungsarten sollen als Kategorien für dieses Experiment dienen.

Ziel dieses Experiments ist festzuhalten, ob in den beiden Modellen die Trainingsbegriffe zu ihren ähnlichen Wörtern unterschiedliche Arten von Beziehungen haben. Die Auswertung der Testbegriffe und ihrer ähnlichen Wörter erfolgt hier wieder von Hand. Sobald eine Beziehungsart in mindestens drei der fünf ähnlichen Wörter abgebildet ist, wird dieser Testbegriff mit der jeweiligen Beziehungsart markiert. Erreicht keine Art drei Vorkommen, wird dieser Begriff mit **verschiedenes** markiert, da hier eine Art nicht eindeutig zuordenbar ist. Somit ergeben sich die sechs endgültigen, unterschiedlichen Beziehungskategorien *syntaktisch*, *synonym*, *gleiches*, *gegenteiliges*, *in Beziehung* und *verschiedenes*. Es werden alle 236 Testbegriffen für dieses Experiment verwendet.

Durchführung

Für dieses Experiment werden beide Modelle untersucht, um eine Aussage zu treffen, ob sich die Beziehungsarten unterscheiden. Auch hier wird von Hand die Art, die die Beziehung zwischen den einzelnen Testbegriffen und den dazugehörigen ähnlichen Wörtern beschreibt, dem jeweiligen Testbegriff zugeordnet. In der Tabelle 5.7 werden die Beziehungsarten und die Anzahl der Testbegriffe, die mit der jeweiligen Art markiert sind, nach Modelltyp getrennt, dargestellt. In der darauffolgenden Tabelle 5.8 sind Beispiele zu den einzelnen Beziehungsarten aufgelistet. Neben der Art der Beziehungen ist der Suchbegriff, Modelltyp und die ähnlichen Worte mit den dazugehörigen Kosinusähnlichkeiten abgebildet.

Tabelle 5.7: Experiment 4: Arten von Beziehungen

Beziehungsart	Gesamtmodell	Technologie- modell
syntaktisch	0	0
gegenteilig	0	0
gleiches	81	38
synonym	0	0
in Beziehung	118	126
verschiedenes	37	47
nicht im Modell enthaltene Worte	0	25

Tabelle 5.8: Beispiele zur den verschiedenen Beziehungsarten

Art	Suchbegriff	Modell	Ähnliche Worte
gleiches	chrome	Komplett Technologie	firefox (0,784), safari (0,686), ie8 (0,674) firefox (0,733), safari (0,769), flock (0,667), seamonkey (0,650)
in Beziehung	browser	Komplett	browsers (0,882), firefox (0,812), desktop (0,755), javascript (0,751)
verschiedenes	itunes	Komplett	spotify (0,770), beatport (0,756), preorder (0,718), download (0,694)

Interpretation/Ergebnis

gegenteilig absolut gar nicht

Die Arten *synonym* und *syntaktisch* traten, bei den in der Arbeit verwendeten Testdaten, nicht auf. TODO: Da wieder erst ab 3 von 5 ähnlichen Wörtern gezählt wurde, ist bei *synonym* = 0, aber in experiment 1 wurden synonyme gefunden (allerdings nicht bei ähnlichen wörtern, sondern deren ähnliche wörter). es waren auch synonyme unter den ähnlichen wörtern der etstwörter, allerdings jeweils nur 1-2 und somit viel dieses wort in eine andere kategorie oder mixed.

Wie man in der Auswertung der Daten erkennt, ist bei beiden Korpora die Beziehungsart *in Beziehung* am stärksten vorhanden, dies kommt daher, dass im Word2Vec Modell Wörter die in ähnlichem Kontext stehen, auch nahe in der Vektorrepräsentation zusammen stehen. Die Art *gleiches* ist im kompletten allgemeinen

Korpus mit 34,3% die zweithäufigste Art, allerdings kommt sie im Technologiekorpus nur ca. halb so oft vor (19,9%). Hingegen ist die Anzahl mit *verschiedenen* Arten etwas höher, sowie die *in Beziehung*. Der Unterschied zwischen den Beziehungsarten in den unterschiedlichen Korpora ist also nicht zu groß, allerdings deutlich erkennbar.

5.5 Erkennen von Mehrdeutigkeit

Beschreibung

Das letzte Experiment beschäftigt sich mit der Mehrdeutigkeit von Worten. Es soll untersucht werden, ob im allgemeinen kompletten Korpus die unterschiedlichen Bedeutungen eines mehrdeutigen Wortes in den ähnlichen Worten repräsentiert werden.

Durchführung

Auch hier wurden beide Korpora analysiert um zu vergleichen ob sie sich unterscheiden im Bezug auf mehrdeutige Worte.

Tabelle 5.9: Experiment 5: Erkennen von Mehrdeutigkeiten

	Kompletter Korpus	Relation zur Gesamtzahl	Technologie-Korpus	Relation zur Gesamtzahl
Wort nicht im Korpus	0	0,0%	24	10,2%
nicht mehrdeutig	172	72,9%	148	62,7% (70,1%)
mehrdeutig	64	27,1%	64	27,1% (30,3%)
	Kompletter Korpus	Relation zu mehrdeutigen Worten	Technologie-Korpus	Relation zu mehrdeutigen Worten
Wort nicht im Korpus	0	0,0%	1	1,7%
nicht erkannt	58	90,6%	57	89,1%
erkannt	6	9,4%	6	9,4%

Die Prozentangabe in Klammern bezieht sich auf die Relation zu den im Korpus enthaltenen Worten (211 Stück) und nicht auf die Gesamtzahl an Testdaten(236 Stück).

Tabelle 5.10: Beispiele zur Erkennung von Mehrdeutigkeiten

Suchbegriff	Korpus	Erkannt	Ähnliche Worte
trojan	Komplett	ja	rsplug (Kosinusähnlichkeit: 0,472), athena (0,462)
	Technologie	ja	bundestrojaner (0,496), centaurs (0,475), horse (0,586), malware (0,560), zinaps (0,476)
raspberry	Komplett	nein	apple (0,657), apricot (0,629), blackcurrant (0,586),
	Technologie	nein	pi (0,677), cubieboard (0,524), trimeslice (0,519)

Interpretation/Ergebnis

Erstaunlicherweise unterscheiden sich in diesem Experiment die beiden Korpora nicht in der Anzahl der erkannten Mehrdeutigkeiten. Allerdings hat öfters das eine Modell eine Bedeutung abgedeckt und das andere Modell eine oder die andere.

Es ist deutlich zu erkennen, dass beide Modelle nicht geeignet sind um eine Mehrdeutigkeit in den Testdaten in ihren ähnlichen Worten abzubilden.

Somit ist die Annahme dieses Experiments widerlegt.

Kapitel 6

Fazit und Ausblick

6.1 Fazit

Nach einer ausführlichen Vorverarbeitung können die Artikel aus Wikipedia gut als Trainingsdaten für Word2Vec Modelle dienen. Dank der Gensim-Implementierung ist die Benutzung von Word2Vec sehr vereinfacht und kann komfortabel bedient werden.

Die Experimente liefern interessante Resultate im Bezug auf die Problemstellung dieser Arbeit. Durch die Experimente können die unterschiedlichen semantischen Beziehungen etwas aufgeschlüsselt werden. So wird durch die Experimente deutlich, dass durch einmalige Rekursion der Suchbegriffe, nicht auf Synonyme des ursprünglichen Begriffs geschlossen werden kann.

Des weiteren eignet sich der domänenspezifische Teilkorpus eher für eine Konkretisierung der Suchbegriffe, wobei dies nur in ca. einem Drittel der Testdaten nachgewiesen werden konnte.

Sollen die Testdaten verallgemeinert werden, eignet sich der allgemeine komplette Korpus viel besser als der domänenspezifische Teilkorpus. Soll also ein Überblick über ein gewisses Thema oder Suchbegriff erhalten werden, wird empfohlen das Modell, welches auf dem allgemeinen kompletten Korpus trainiert wurde, zu verwenden. Die unterschiedlichen Arten von Beziehung zwischen den Testdaten und ihren ähnlichen Wörtern unterscheiden sich nicht grundlegend zwischen den beiden Modellen. Das allgemeine komplette Modell hat einen etwas Größeren Anteil an *gleichen* Worten, hingegen hat das domänenspezifische Teilmodell einen etwas größeren Anteil an *verschiedenen* und *in Beziehung* stehenden Beziehungen. *Synonyme* oder *gegen-teilige* Arten an Beziehungen sind in beiden Modellen nicht vorhanden. Und auch *syntaktische* Beziehungen sind nur bei einem Testdatensatz vorhanden.

Soll auf Mehrdeutigkeit untersucht werden, ist die Vorgehensweise nur die ähnli-

chen Worte zu vergleichen und zu analysieren, nicht zielführend, da die Modelle die Mehrdeutigkeit in den ähnlichen Worten nicht gut abbilden. Im Ausblick wird ein Vorschlag gemacht, wie die Mehrdeutigkeit eventuell besser erfasst werden könnte.

Es kann also festgehalten werden, dass sich das allgemeine komplette Modell dann besser eignet, wenn ein genereller Überblick über die Testdaten erhalten werden soll. Denn in diesem Modell werden die Suchbegriffe eher verallgemeinert und die ähnlichen Worte repräsentieren *Gleiches* im Bezug zu den Testdaten. Soll aber ein Suchbegriff genauer untersucht, bzw. sehr fokussiert betrachtet werden, eignet sich ein domänenspezifisches Modell besser. Dieses konkretisiert die Testdaten nicht nur besser, sondern liefert auch fachspezifischere ähnliche Worte.

Die Qualität der Beziehungen hängt zudem stark von den verwendeten Trainingsdaten ab. Es sollte gewährleistet sein, dass ausreichend viele und auch qualitativ gute Daten zum Training verwendet werden.

Soll ein domänenspezifisches Modell erstellt werden, sollte hier auch darauf geachtet werden, dass nicht nur ein Teil dieser Domäne in den Trainingsdaten abgebildet ist, außer es soll nur dieser spezielle Teil der Domäne im Modell dargestellt werden.

6.2 Ausblick

In dieser Arbeit wurden Beziehungen zwischen den Testdaten und ihren ähnlichen Worten analysiert. Es wurden jedoch bei weitem nicht alle Beziehungen untersucht, weshalb der Fokus weiterführender Arbeiten andersartige Beziehungen zwischen den Wörtern sein könnten. Dies bedeutet, dass noch mehrere Experimente durchgeführt werden würden. Zum Beispiel könnte die Mehrdeutigkeit noch anders untersucht werden, indem man mehrere unterschiedliche Modelle hat und dann die ähnlichen Worte eines gleichen Testwortes vergleicht.

Ein weiterer Ansatzpunkt für zukünftige Arbeiten ist, wie sich subsampling¹ im Word2Vec Modell, im Blick auf die in dieser Arbeit analysierten Fragestellungen, verhält. Es wäre auch möglich das Word2Vec Modell mit N-Grammen, auch Phrases genannt, zu lernen, dann könnten auch Mehrwortbegriffe abgebildet und gesucht werden.

¹Beim subsampling wird das Ungleichgewicht von sehr häufig und sehr selten vorkommenden Worten im Trainingskorpus verringert[MSC⁺13].

Literaturverzeichnis

- [MCCD13] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *CoRR*, abs/1301.3781, 2013.
- [MSC⁺13] Tomas Mikolov, Ilya Sutskever, Kai Chen, Greg Corrado, and Jeffrey Dean. Distributed representations of words and phrases and their compositionality. *CoRR*, abs/1310.4546, 2013.
- [MYZ13] Tomas Mikolov, Wen-tau Yih, and Geoffrey Zweig. Linguistic regularities in continuous space word representations. In *Human Language Technologies: Conference of the North American Chapter of the Association of Computational Linguistics, Proceedings, June 9-14, 2013, Westin Peachtree Plaza Hotel, Atlanta, Georgia, USA*, pages 746–751, 2013.
- [ŘS10] Radim Řehůřek and Petr Sojka. Software Framework for Topic Modeling with Large Corpora. In *Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks*, pages 45–50, Valletta, Malta, May 2010. ELRA. <http://is.muni.cz/publication/884893/en>.

Tabellenverzeichnis

4.1	Vergleich Parameter	11
4.2	Testdatenvergleich	13
5.1	Experiment 1: Synonyme durch Rekursion	15
5.2	Beispiele von Synonyme durch Rekursion	16
5.3	Experiment 2: Konkretisierung	19
5.4	Beispiele zur Konkretisierung	19
5.5	Experiment 3: Verallgemeinerung	22
5.6	Beispiele zur Verallgemeinerung	22
5.7	Experiment 4: Arten von Beziehungen	24
5.8	Beispiele zur den verschiedenen Beziehungsarten	24
5.9	Experiment 5: Erkennen von Mehrdeutigkeiten	25
5.10	Beispiele zur Erkennung von Mehrdeutigkeiten	26
7.1	Testdaten aus der Domäne Mode/Fashion	32
7.2	Testdaten aus der Domäne Medizin	33
7.3	Testdaten aus der Domäne Technologie/Pc/Internet	33
7.4	Vollständige Testdaten Teil 1	34
7.5	Vollständige Testdaten Teil 2	35
7.6	Synonymliste	39

Abbildungsverzeichnis

3.1	CBOW und Skip-gram im Vergleich, übersetzt nach [MCCD13]	6
5.1	Beispiel der Beziehungen zwischen Wörtern als Baumdiagramm dargestellt.	18
5.2	Beispiel der Beziehungen zwischen Wörtern als Baumdiagramm dargestellt.	21

Kapitel 7

Anhang

7.1 Testdatenvergleich

Auflistung der Testdaten, die zum Vergleich der Testdomänen benutzt wurden.

Tabelle 7.1: Testdaten aus der Domäne Mode/Fashion

apron	babydoll	bandana	belt
beret	bermuda	bikini	blazer
blouse	boot	boxer	cap
cargo	chaps	chesterfield	coat
cufflink	cummerbund	fashion	fedora
gaiters	handbag	handkerchief	hat
headband	helmet	hood	hoodie
jacket	jersey	jewellery	muff
necktie	negligee	pajamas	pantsuit
sash	shawl	shirt	shrug
sleeveless	slip	sweater	trunks
turban	umbrella	undershirt	veil
wallet	wetsuit		

Tabelle 7.2: Testdaten aus der Domäne Medizin

allergy	anatomy	arthritis	aseptic
cardiology	cell	clinic	cornea
dental	disability	disease	ect
excision	finger	fistula	gynaecology
hemostat	hernia	hospital	immunology
iris	knee	limb	lip
mammography	medicine	mouth	mri
nephrology	oncology	otoplasty	pain
prolapse	prosthesis	radiology	radiotherapy
retina	scalpel	scapula	skeleton
skull	sterile	surgery	symptom
tomography	transplant	ultrasound	urology
wrist	xray		

Tabelle 7.3: Testdaten aus der Domäne Technologie/Pc/Internet

acer	amazon	apple	arcade
arpanet	biometrics	blogging	chrome
cookies	cyberwar	dell	drone
dropbox	events	filesharing	firefox
foursquare	gameplay	groupon	hacking
instagram	lenovo	macintosh	malware
microsoft	mobile	motoring	mouse
myspace	paypal	pc	photography
playstation	processor	ram	raspberry
samsung	software	sony	starcraft
steam	surface	tablet	tetris
tumblr	twitter	warcraft	windows
yahoo	youtube		

7.2 Testdaten

Tabelle 7.4: Vollständige Testdaten Teil 1

3d	3ds	3g	4chan
4g	acer	acta	activision
adobe	amazon	android	anonymous
aol	apple	app	augmented
arcade	architecture	arpanet	asus
auto	automobile	battlefield	bing
biometrics	bitcoin	bittorrent	blackberry
blizzard	blogging	blog	bluray
broadband	browser	casual	chatroulette
chrome	chromebook	cispa	computing
console	cookies	craigslist	crowdfunding
crowdsourcing	cryptocurrency	cybercrime	cyberwar
darknet	data	dell	diablo
doodle	dotcom	drone	dropbox
e3	ebay	email	emoji
encryption	energy	engine	engineering
ereader	events	facebook	fat
filesharing	firefox	flickr	foursquare
gadget	game	gameplay	gamergate
games	gaming	ghz	gmail
google	googlemail	gps	groupon
gta	hacking	halo	handheld
hardware	hashtag	hd	heartbleed
htc	html5	i	ibm
icloud	ie	imac	indie
instagram	intel	internet	ios
ipad	iphone	ipod	isp
itunes	keyboard	kickstarter	kindle
kinect	laptop	lenovo	lg
limewire	link	linkedin	linux
live	machinima	macintosh	macworld
malware	mario	megaupload	microsoft
minecraft	mmorpg	mobile	monitor
motoring	mouse	mozilla	myspace
nes	net	netbook	nfs
nintendo	nokia	oracle	ouya
p2p	paypal	pc	phablet
phishing	photography	photoshop	pi
pinterest	piracy	pirate	platform

Tabelle 7.5: Vollständige Testdaten Teil 2

playback	playstation	pokemon	power
processor	programming	ps	ps2
ps3	ps4	psp	python
raider	ram	raspberry	rayman
recommendation	reddit	retro	robot
rpg	rts	safari	samsung
search	security	seo	skype
smartphone	smartphones	smartwatch	smartwatches
software	sonic	sony	sopa
spam	spotify	steam	stream
starcraft	stuxnet	sun	surface
symbian	tablet	technology	technophile
ted	telecom	television	tetris
titanfall	tomb	trojan	tumblr
twitch	twitter	viber	vine
virus	warcraft	web	whatsapp
wheel	wifi	wii	wikipedia
windows	windows7	wireless	worms
wow	xbox	xp	y2k
yahoo	youtube	zelda	zynga

7.3 Reinigungsskript

Das Originalskript von Matt Mahoney kann unter <http://mattmahoney.net/dc/textdata.html> gefunden werden.

```
#!/usr/bin/perl

# Program to filter Wikipedia XML dumps to "clean" text consisting only
# of lowercase letters (a-z, converted from A-Z), and spaces
# (never consecutive).
# All other characters are converted to spaces. Only text which normally
# appears in the web browser is displayed. Tables are removed.
# Image captions are
# preserved. Links are converted to normal text.
# Digits are spelled out.

# Written by Matt Mahoney, June 10, 2006. This program is
# released to the public domain.

$/=">";          # input record separator
while (<>) {
    if (/<text /) {$text=1;} # remove all but between <text> ... </text>
    if (/#redirect/i) {$text=0;} # remove #REDIRECT
    if ($text) {

        # Remove any text not normally visible
        if (/<\text>/) {$text=0;}
        s/<.*>//;          # remove xml tags
        s/&#/g;             # decode URL encoded chars
        s/&lt;/g;
        s/&gt;/>/g;
        s/<ref[<]*</ref>/g; # remove references <ref...> ... </ref>
        s/<[>]*>/g;        # remove xhtml tags
        s/[http:[^ ]]*[/g;   # remove normal url, preserve visible text
        s/\\thumb//ig;       # remove images links, preserve caption
        s/\\|left//ig;
```

```

s/\\|right//ig;
s/\\|\\d+px//ig;
s/\\[\\[image:[^\\[\\]]*\\|//ig;
# show categories without markup
s/\\[\\[category:([^\|\\]]*)([^\|\\]]*\|\\)/[[ $1 ]]/ig;
s/\\[\\[\\[a-z\\-]*:[^\\[\\]]*\\|\\]\\]/g; # remove links to other languages
s/\\[\\[\\[^\|\\]]*\\|\\|/g; # remove wiki url, preserve visible text
s/{[^\|\\]]*}/g; # remove {{icons}} and {tables}
s/{[^\|\\]]*}/g;
s/[/]/g; # remove [ and ]
s/\\]/g;
s/&[^\|\\]]*; / /g; # remove URL encoded chars

$_=" $_ ";
##### begin changed lines #####
s/Ä/Ae/g;
s/ä/ae/g;
s/Ö/Oe/g;
s/ö/oe/g;
s/Ü/Ue/g;
s/ü/ue/g;
s/ß/ss/g;
s/-//g;
#removes everything else than this characters
tr/0-9A-Za-z,.!?:\\r\\n / /csd;
##### end changed lines #####
chop;
print $_;
}
}

```


7.4 Synonymliste

Tabelle 7.6: Synonymliste

Wort	Synonym
acer	genusacer, dicotgenus, magnoliopsidgenus
adobe	brick, adobebrick, clay
amazon	woman, virago, parrot, adultfemale, amazonriver, mythicalbeing, river
android	golem, automaton, humanoid, mechanicalman, robot
anonymous	unidentified, onymous, faceless, anon., unknown, nameless, unnamed
apple	falsefruit, appletree, maluspumila, ediblefruit, pome, orchardappletree
arcade	construction, structure, colonnade, passageway
architecture	building, discipline, finearts, computerarchitecture, beauxarts, profession, study
augmented	increased
auto	car, automobile, machine, motorvehicle, motorcar, automotivevehicle
automobile	auto, car, travel, move, machine, go, locomote, motorvehicle, motorcar, automot
battlefield	fieldofhonor, parcel, pieceofground, field, tract, fieldofbattle, pieceofland, battleg
biometrics	statistics, lifescience, bioscience, biostatistics, biometry
blackberry	blackberrybush, bramblebush, berry, drupelet
blizzard	series, rash, violentstorm, snowstorm, storm
blog	communicate, weblog, diary, journal, intercommunicate
broadband	wideband, band, system
browser	looker, viewer, watcher, application, webbrowser, spectator, applicationsprogram
casual	occasional, fooling, unplanned, irregular, accidental, nonchalant, light, unconcer
chrome	plate, atomicnumber24, process, chromiumplate, cr, chromium, treat
computing	appliedscience, calculation, computerscience, engineeringscience, process, engine
console	solace, housing, comfort, consoletable, cabinet, soothe, bracket, table, scientifici
cybercrime	lawbreaking, crime
cyberwar	cyberterrorism, terrorism, actofterrorism, terroristact
data	assemblage, information, aggregation, collection, accumulation
dell	dingle, holler, hollow
doodle	scrabble, draw, scribble, drawing
drone	heavierthanaircraft, bourdon, dawdler, droneon, laggard, idler, go, utter, speak,
email	electronicmail, snailmail, telecommunicate, electroniccommunication, netmail
encryption	secretwriting, steganography, coding, cryptography, encoding
energy	force, healthiness, goodhealth, executivedepartment, strength, zip, liveliness, vig
engine	railwaylocomotive, causalagency, selfpropelledvehicle, causalagent, motor, locom
engineering	discipline, appliedscience, room, field, study, profession, fieldofstudy, engineering
fat	heavy, lipide, paunchy, fleshout, loosejowled, animaltissue, portly, porcine, avoin
foursquare	square, regularpolygon, resolute, straightforwardly, squarely, rectangle
gadget	contraption, gismo, appliance, widget, convenience, contrivance, device, gizmo
game	brave, job, back, competition, stake, halting, unfit, animatebeing, wager, occupa
gaming	recreation, gambling, play, diversion, vice
ghz	gigacycle, rate, gc, gigahertz, gigacyclepersecond
google	search, explore, searchengine, research
gps	globalpositioningsystem, navigationalsystem
halo	annulus, toroid, anulus, glory, gloriole, nimbus, light, anchoring, atmosphericph
handheld	
hardware	instrumentation, software, munition, component, arms, computerhardware, iron
i	digitalizing, for, digitalizing, digitalizing, digitalizing, digitalizing, digitalizing